



ESG 文本分類模型研究

機器學習概論期末專題報告

U11216005 資料三 侯上云

Abstract



動機與目的

動機

隨著全球對永續發展與企業社會責任（ESG）的重視，上市櫃永續報告書成為評估企業非財務表現的重要依據。然而，動輒數百頁的永續報告書包含大量繁複的文字資訊，若仰賴人工審查不僅耗時耗力，更難以建立客觀且標準化的量化評級。因此，如何利用自然語言處理（NLP）技術，從中自動化抓取並精確分類關鍵的 ESG承諾與實質證據，成為金融科技與資訊科學領域的重要課題。

目的

此報告針對ESG文本發展高效的多任務分類模型，將整體任務拆成四大核心子任務進行預測



相關研究-BERT模型架構

BERT (Bidirectional Encoder Representations from Transformers) **核心架構：**

Transformer Encoder


BERT 的本體是由多層的 Transformer 編碼器 (Encoder) 堆疊而成

輸入層 (Input Representation)： 包含三個輸入向量相加 Token Embeddings、Segment Embeddings、Position Embeddings


預訓練階段 (Pre-training)： 透過大量無標籤文本學習語言規律，主要包含兩個任務 Masked LM (MLM)、Next Sentence Prediction (NSP)

微調階段 (Fine-tuning)： 一旦預訓練完成，我們只需要在 BERT 上方加上一個簡單的輸出層 (Output Layer)，並使用特定任務的標記資料 (如 SQuAD 問答、MNLI 推理、NER 實體辨識) 進行訓練。

BERT的邏輯是先大量資料中學會讀書 (預訓練)，再針對具體考卷進行重點複習 (微調)。



研究方法-文本長度分布



超過 MAX_LEN=512 的樣本數: 17 (1.7%)

文本長度分布 左截斷*

- 在初始化 BertTokenizer 時，設定`tokenizer.truncation_side = 'left'`。
- 為什麼要截斷？當輸入文本長度超過 `MAX_LEN = 512` 時，模型會捨棄文本開頭的內容，**保留最末端的 512 個 Token**。
- 為什麼適用？在 ESG 文本分析任務中，關鍵的證明資訊或總結性的承諾語句通常出現在段落末尾。
- 這樣做可以防止關鍵資訊流失，若採用預設的右截斷（保留開頭），模型可能會因為抓不到位於文本後方的「證據品質」或「達成時間線」等資訊，而導致 `evidence_quality` 或 `verification_timeline` 任務的分數下降。

研究方法-使用技術

從「兩層融合」進化到「12 層動態權重」

一開始訓練的BERT只有把最後兩層相加，但為了要讓加權分數增加使用了`self.layer_weights`，讓模型能自動學習

R-DROP 與 FGM 雙重疊加

- R-Drop：同一筆資料過兩次模型並計算 KL 散度，強迫模型的 Dropout 在不同隨機狀態下都能輸出一致的結果，提升模型的穩定性。
- FGM (Fast Gradient Method)：在 Embedding 層加入微小擾動進行對抗訓練，讓模型不僅學會分類，還學會抗干擾。

5-Fold 集成預測 (Ensemble)

提升分數最穩定的方法，單一模型容易對特定資料產生偏誤，透過 `run_final_test_ensemble` 將 5 個 Fold 的模型預測機率相加取平均，消除單一模型的偶然錯誤。

LLRD (Layer-wise Learning Rate Decay)

越靠近底層的參數學習率越小，越靠近頂層（靠近任務輸出）的學習率越大，保護BERT預訓練好的底層資料不被破壞，同時讓頂層能快速適應ESG任務。

實驗設定-資料集切分

使用AI CUP ESG競賽資料集

資料集切分主要分為兩種不同階段的切分方式

2/8 分法 (Hold-out Split)

Train-Test Split :





- 訓練集 (Training Set) : 佔總資料量的 80% 。
- 測試集 (Testing Set) : 佔總資料量的 20% 。
- 使用 `train_test_split` 函數，並將 `random_state` 設為 42 以確保實驗的可重複性。

5-Fold Cross-Validation (五折交叉驗證)

- 最終測試集 (Final Test Set) : 預先撥出 10% 的資料作為完全不參與訓練的測試集 (Unseen Data) 。
- 交叉驗證 (Cross-Validation) : 剩下的 90% 資料被平均分成 5 份 (Folds) 。
 - 在每一輪訓練中，會輪流將其中 1 份作為「驗證集」，其餘 4 份作為「訓練集」。
 - 這過程會重複 5 次，確保模型在資料集的不同子集上都經過驗證。
- 使用 `KFold` 方法，同樣設定 `random_state=42`

實驗設定-四大子任務分布

Training data label distribution




實驗結果-模型加權分數比較

模型	BERT	DistilBERT	BERT
加權分數	0.59106	0.54917	0.66297
資料切分策略	2/8 分法 (Hold-out)	2/8 分法 (Hold-out)	5-Fold 交叉驗證 + 10% 獨立測試
特徵提取技術	最後兩層融合 (Sum)	僅取 [CLS] Token	12 層全層動態加權融合 (Dynamic Fusion)
訓練穩定化	基礎訓練	Label Smoothing	FGM 對抗訓練 + R-Drop 雙向正規化
優化器策略	分層學習率	單一學習率 + AdamW	LLRD (分層學習率衰減) + SWA (隨機加權平均)
預測模式	單一模型預測	單一模型預測	5-Fold 模型集成 (Ensemble)



實驗結果-四大任務標籤分布

任務名稱 (Task)	標籤分布 (Labels)	任務權重	Marco-F1 score
promise_status	Yes, No	20%	0.7379
verification_timeline	already, within_2_years, between_2_and_5_years, longer_than_5_years, N/A	15%	0.5899
evidence_status	Yes, No, N/A	30%	0.6404
evidence_quality	Clear, Not Clear, Misleading, N/A	35%	0.6708

實驗結果-四大任務標籤分布



實驗結果-訓練曲線



左圖: 曲線平滑且穩定下降，代表模型正在有效地學習 ESG 文本任務的特徵，沒有出現明顯的梯度震盪。

右圖: 在第 16 個 Epoch 時達到了最終目標分數 0.66297（圖中紅虛線）在Epoch 10 之後分數雖然波動較小，但仍有微幅上升，因為使用了 SWA（隨機加權平均）

遇到的問題

類別極度不平衡問題

在 ESG 數據中，某些標籤（如 evidence_quality 中的 "Misleading"）出現頻率極低，而 "Clear" 可能佔絕大多數。

長文本資訊遺失問題

雖然使用了左截斷，但如果一份 ESG 報告的關鍵證據剛好在正中間，或是同時分散在開頭與結尾，左截斷會讓模型產生盲點。

語義模糊與專業術語問題

ESG 文本含有大量的專業金融與環保術語（如：SBTi、Scopes 1/2/3），bert-base-chinese 可能對這些特定領域的術語理解不夠深入。

可優化方向

處理長文本的進階策略

Sliding Window (滑動視窗): 不使用單一截斷法，而是將長文本切成多個段落進入模型，最後再將特徵匯總 (Pooling)。

數據增強 (Data Augmentation)

同義詞替換 (EDA): 針對樣本數較少的類別進行擴充。

損失函數與架構微調

Dice Loss: 對於極度不平衡的類別，Dice Loss 可能比 Focal Loss 更能有效處理邊界樣本。

結論

模型現在已經不是在猜標籤，而是透過對抗訓練（FGM）和雙向規範（R-Drop）學會在ESG長文本中抓重點，透過全層動態融合與左截斷精確捕捉到隱藏在長文本結尾的關鍵證據，這讓Macro-F1四個子任務相加加權分數從 0.59 衝上 0.66。

雖然模型對於承諾狀態的判斷已經非常精準，但在處理「多分類的時間區間」仍有進步空間。

參考資料

BERT模型架構 [HTTPS://HAREN.MEDIUM.COM/PAPER-NOTES-BERT-BERT-%E6%9E%B6%E6%A7%8B%E7%90%86%E8%A7%A3-31C014D7DD63](https://haren.medium.com/paper-notes-bert-bert-%E6%9E%B6%E6%A7%8B%E7%90%86%E8%A7%A3-31C014D7DD63)

BERT [HTTPS://FORUMS.LEADTEK.COM/TW/THREAD/18867](https://forums.leadtek.com/tw/thread/18867)

AI × ESG — 台灣上市櫃永續報告書智慧分析

[HTTPS://PAPERLAB.COOPERATION.TW/CASES/ESG/](https://paperlab.cooperation.tw/cases/esg/)

BERT公開資料集 [HTTPS://GITHUB.COM/QAWL987/ESG-BERT-ANALYZING-REPORTS/BLOB/MASTER/MAIN.IPYNB](https://github.com/QAWL987/ESG-BERT-ANALYZING-REPORTS/blob/master/main.ipynb)



**THANK YOU
FOR LISTENING**