

期末專題報告

U11216005 資科三 侯上云

一、題目

ESG 文本分類模型研究

二、摘要

此報告聚焦於台灣上市櫃企業永續報告書（ESG）文本分類，面對多任務分類中的類別極度不平衡、長文本資訊遺失及專業術語理解不足等問題，此報告基於預訓練語言模型 BERT 進行深度微調與優化，結合「12 層動態加權融合」、「左截斷文本處理」、「FGM 對抗訓練與 R-Drop 雙向正規化」，以及「分層學習率衰减（LLRD）與隨機加權平均（SWA）」的架構，實驗結果顯示，在 AI CUP ESG 競賽資料集中，此報告成功將四大子任務的總加權 Macro-F1 分數從基準模型的 0.59106 大幅提升至 0.66297。

三、介紹

3.1 研究動機

隨著全球對永續發展與企業社會責任（ESG）的重視，上市櫃永續報告書成為評估企業非財務表現的重要依據。然而，動輒數百頁的永續報告書包含大量繁複的文字資訊，若仰賴人工審查不僅耗時耗力，更難以建立客觀且標準化的量化評級。因此，如何利用自然語言處理（NLP）技術，從中自動化抓取並精確分類關鍵的 ESG 承諾與實質證據，成為金融科技與資訊科學領域的重要課題。

3.2 研究目標

此報告針對 ESG 文本發展高效的多任務分類模型，將整體任務拆成四大核心子任務進行預測：

- promise_status：判斷企業是否做出承諾。
- verification_timeline：評估其承諾的達成時間線。
- evidence_status：檢視文本中是否包含支持承諾的證據。
- evidence_quality：鑑定該證據的品質與可信度。

此報告的目標在於克服真實文本資料中極端的類別不平衡與長文本限制，透過模型架構、訓練穩定化及優化器策略的整合優化，極大化整體的加權分數。

四、相關研究

4.1 BERT 模型架構

BERT (Bidirectional Encoder Representations from Transformers) 的核心架構是由多層 Transformer 編碼器 (Encoder) 堆疊而成的雙向深度神經網路。其輸入層 (Input Representation) 透過融合 Token Embeddings、Segment Embeddings 與 Position Embeddings 來捕捉文本字詞、句子關係與位置資訊。

4.2 預訓練與微調 (Pre-training and Fine-tuning)

BERT 的訓練邏輯採取兩階段策略：

1. 預訓練階段 (Pre-training)：在大量無標籤文本上，透過 Masked Language Model (MLM) 與 Next Sentence Prediction (NSP) 任務，使模型學會通用的語言規律與上下文語義。
2. 微調階段 (Fine-tuning)：在預訓練好的 BERT 模型上方加入針對特定任務設計的簡單輸出層 (Output Layer)，並灌入特定任務的標記資料（如問答、推理、實體辨識或分類任務）進行重點複習與參數更新。

五、研究方法

此報告從特徵提取、訓練穩定化以及優化策略三個方面進行改進。

5.1 文本長度處理：左截斷策略

由於 BERT 具有 512 文本長度限制，在初始化 BertTokenizer 時，將截斷方向修改為左截斷 (tokenizer.truncation_side = 'left')。

- 原理：當輸入文本長度超過時，模型會捨棄開頭，保留最末端的 512 個 Token。
- 適用性：在 ESG 文本分析中，關鍵的證明資訊、數據證據或總結性的承諾語句通常落在段落末尾，若使用預設的右截斷，模型容易漏失位於後方的「證據品質」或「達成時間線」等關鍵指標。

5.2 特徵提取技術：12 層動態加權融合

傳統做法只提取最後兩層進行簡單相加（Sum），或是只取[CLS]節點的特徵，引入 self.layer_weights 參數，讓模型在訓練過程中自動學習 BERT 全部 12 層 Transformer Encoder 的權重比例，動態融合不同深度所捕捉到的語義、句法與上下文特徵，從而更精準地判斷複雜的 ESG 多任務分類。

5.3 訓練穩定化

- FGM 對抗訓練：在模型的 Embedding 層中加入微小的梯度擾動，迫使模型在面對帶有噪聲的輸入時仍能正確分類，大幅提升其抗干擾能力與泛化性。
- R-Drop 雙向正規化：將同一個輸入資料在同一個訓練內連續兩次送入模型，由於 Dropout 的隨機性，兩次輸出的機率分布會有微幅差異，R-Drop 藉由計算兩者之間的 KL 散度將其納入損失函數，強迫模型在不同隨機狀態下保持輸出的一致性，有效抑制過擬合。


5.4 優化器與預測策略

- LLRD：實施分層學習率衰減，越靠近底層的參數學習率越小（保護預訓練好的通用語言表徵不被破壞），越靠近頂層（任務輸出層）的學習率越大，使其快速適應 ESG 任務。
- SWA：在訓練後期對多個 Checkpoint 的模型權重取平均，能有效引導模型走向更平滑的局部極小值，提升測試集上的穩定度。
- 5-Fold 模型集成：將 5 個交叉驗證訓練出的獨立模型進行集成預測，透過 run_final_test_ensemble 將各模型輸出的預測機率相加取平均後再進行分類決策，有效消除了單一模型的偶然偏誤與錯誤。

六、資料集與實驗設定

6.1 資料來源與特性

報告採用 AI CUP ESG 競賽資料集訓練集（台灣上市櫃永續報告書智慧分析）。透過文本長度統計，資料的平均字數為 208 字，但有約 1.7%（17 個樣本）超過了 BERT 的 512 Token 限制，證實了截斷策略的必要性。



6.2 標籤分布與極度不平衡問題

資料集在各子任務的標籤分布上呈現嚴重的長尾與不平衡現象：

- `promise_status` (權重 20%) : Yes 佔 81.4% (814 筆), No 僅佔 18.6% (186 筆)。
- `verification_timeline` (權重 15%) : 類別極多, 其中 `already` 佔 30.0% , 而 `within_2_years` 僅有 1.3% (13 筆)。
- `evidence_status` (權重 30%) : Yes 佔 67.7% (677 筆), 其餘為 No 與 N/A。
- `evidence_quality` (權重 35%) : Clear 為主流 (55.2%), 而偏誤類別 `Misleading` 僅有 1 筆 (0.1%), 造成嚴重的分類邊界干擾。

6.3 資料集切分策略

在不同階段採取了兩種不同的切分實驗：

1. 2/8 分法：80%投入訓練，20%用於測試，可以快速驗證基礎模型。
2. 5-Fold 交叉驗證+10%獨立測試：預先留 10%作為完全不參與訓練的全新測試集，剩下的 90%資料平均分為 5 份，輪流以 4 份作為訓練集、1 份作為驗證集，重複跑 5 次，所有切分皆固定 `random_state=42` 以確保可重複性。

七、實驗結果


7.1 不同模型策略之效能對比

以下為報告中所嘗試的三種模型配置與最終加權分數 (Weighted F1-score) 的

對比：

模型	BERT	DistilBERT	BERT
加權分數	0.59106	0.54917	0.66297
資料切分	2/8 分法	2/8 分法	5-Fold 交叉驗證 + 10%獨立測試
特徵提取	最後兩層融合	僅取[CLS]Token	12 層動態加權融合
訓練穩定化	基礎訓練	Label Smoothing	FGM 對抗訓練 + R-Drop 雙向正規化
優化器策略	分層學習率	單一學習率+ AdamW	LLRD（分層學習率衰減）+ SWA（隨機加權平均）
預測模式	單一模型預測	單一模型預測	5-Fold 模型集成

7.2 訓練收斂曲線分析



- 訓練損失 (Training Loss)：曲線呈現平滑且穩定的下降趨勢，代表模型正在有效地學習 ESG 文本任務的特徵，沒有出現明顯的梯度震盪或發散。
- 驗證集表現 (Validation Performance)：在第 16 個 Epoch 時，驗證集得分達到了加權分數 0.66297，在第 10 個 Epoch 之後，分數雖然波動變小，但因為使用了 SWA（隨機加權平均）對參數空間的平滑化，依然有微幅的爬升。

八、可優化方向

8.1 目前遇到的問題

1. 稀有類別的干擾：Misleading 標籤樣本過少，模型在極端不平衡下難以學到足夠的邊界特徵。
2. 長文本盲點：使用左截斷雖然能有效捕捉結尾證據，但關鍵資訊若是不幸分散在文本正中間或開頭，仍會面臨資訊遺失問題。
3. 專業術語未能學習完成：bert-base-chinese 對於高度專業的綠色金融與碳盤查術語（如：SBTi、Scopes 1/2/3）的敏感度仍有提升空間。

8.2 未來優化方向

- 長文本進階策略：未來計劃導入滑動視窗法（Sliding Window），將長文本切成多個具重疊性的段落分別送入模型，最後透過 Pooling 匯總特徵。
- 數據增強：針對稀有類別使用同義詞替換（EDA）或生成式技術進行樣本擴充。
- 損失函數升級：引入 Dice Loss 來取代現有 Focal Loss，以更有效率地處理極度不平衡的邊界樣本分類。

九、結論

此報告證明了透過結構優化與訓練穩定化技術，通用預訓練模型在特定的 ESG 多任務分類上能展現出極佳的適應力，透過結合 FGM 對抗訓練與 R-Drop 雙向正規化，模型已成功擺脫「盲目猜測標籤」的階段，而是真正學會在密集的 ESG 長文本中提取關鍵特徵，透過 12 層動態融合與左截斷策略，模型精確捕捉到了隱藏在永續報告書文本結尾的關鍵證據，使最終加權分數從基礎的 0.59 大幅躍升至 0.66，此報告不僅在競賽資料集上取得了顯著進步，也為未來企業永續報告書的自動化審查與量化評級奠定了堅實的實作基礎。

十、參考資料

1. BERT 模型架構 <https://haren.medium.com/paper-notes-bert-bert-%E6%9E%B6%E6%A7%8B%E7%90%86%E8%A7%A3-31c014d7dd63>
bert <https://forums.leadtek.com/tw/thread/18867>
2. ESG-BERT 文本分析開源資料集 <https://github.com/qaw1987/ESG-BERT-analyzing-Reports/blob/master/main.ipynb>

3. AI × ESG — 台灣上市櫃永續報告書智慧分析
<https://paperlab.cooperation.tw/cases/esg/>