

期末專題報告計劃書

U11216005 資科三 侯上云

一、題目

ESG 文本分類模型研究

二、摘要

此報告在研究台灣上市櫃企業永續報告書（ESG）文本的多任務分類，針對真實數據中面臨的類別極度不平衡、長文本截斷導致資訊遺失，以及專業術語理解不足等挑戰，此報告基於 BERT 預訓練語言模型進行微調，引入左截斷文本處理、12 層動態加權融合、FGM 對抗訓練與 R-Drop 雙向正規化技術，實驗結果顯示，此方法成功將四大子任務的總加權 Macro-F1 分數由基準模型的 0.59106 提升至 0.66297，能有效支援永續報告書的智慧化審查。

三、Introduction

3.1 Motivation（動機）：

全球資本市場對企業 ESG 評級重視度大增，台灣上市櫃企業依法須定期公布永續報告書，人工審閱需要動輒數百頁的報告非常耗時、耗力且容易有主觀偏誤，需要利用 NLP 技術實現客觀量化評級。

3.2 Objectives（目的/要解決的問題）：

建立能同時預測四大子任務的多任務分類模型：promise_status（承諾狀態）、verification_timeline（達成時間線）、evidence_status（是否具備證據）與 evidence_quality（證據品質）。

核心解決問題：

1. 數據標籤極度不平衡（如 Misleading 僅佔 0.1%）。
2. 512Token 長文本限制導致後半段核心證據流失。
3. 綠色金融與環境術語語意模糊。

四、Related works（文獻探討）

4.1 基礎 BERT 模型架構：基於多層 Transformer 編碼器（Encoder）堆疊，具備強大雙向語意表徵能力，但原生模型很多只取最後一層[CLS]，而且處理不平衡長文本缺乏彈性。

4.2 DistilBERT 輕量化模型：透過知識壓縮參數，推論速度快，但在結構複雜的 ESG 多任務分類上，表徵能力與泛化表現明顯不足。

五、Methods (研究方法)

5.1 文本長度定位：將 truncation_side 設為左截斷，當長度大於 512 時捨棄開頭、保留段落末尾，精準捕捉通常落在後半段的數據佐證與結論性承諾。

5.2 特徵提取：引入可學習權重 self.layer_weights，自動動態融合 BERT 全部 12 層的隱藏狀態，增強語意捕捉。

5.3 訓練穩健化：FGM 與 R-Drop：

- FGM 對抗訓練：在 Embedding 層施加微小梯度擾動，提高抗干擾與泛化能力。
- R-Drop 雙向正規化：將同樣的資料過兩次 Dropout 模型，計算雙向 KL 散度並納入 Loss 懲罰項，約束輸出一致性、抑制過擬合。

5.4 實施 LLRD (分層學習率衰減) 與 SWA (隨機加權平均)，並結合 5-Fold 交叉驗證進行模型集成預測 (Ensemble)。

六、Datasets (資料集)

6.1 資料來源：採用 AI CUP ESG 競賽資料集 (台灣上市櫃永續報告書文本)，文本平均長度 208 字，其中 1.7% 樣本超過 512 限制。

6.2 標籤分布與切分：四大任務皆呈現高度長尾分布 (如 promise_status 中 Yes 佔 81.4%)，實驗採用 2/8 分法 (Hold-out) 進行基礎驗證，並以 5-Fold 交叉驗證搭配 10% 獨立測試進行最終評估 (固定 random_state=42)。

七、Experimental Results, and Conclusion (實驗結果與結論)

7.1 實驗結果對比：

- DistilBERT 輕量模型：加權總分數 0.54917。
- 基礎 BERT 模型：加權總分數 0.59106。
- 優化過後 BERT 模型：加權總分數 0.66297。

7.2 子任務表現：promise_status 得分最高 (0.7379)，而 verification_timeline (0.5899) 因時間區間模糊還有進步的空間。

八、結論

實驗結論參考期末專題報告內容。